



UNIVERSIDAD TÉCNICA PARTICULAR DE LOJA

La Universidad Católica de Loja

FACULTAD DE INGENIERÍAS Y ARQUITECTURA

CARRERA DE CIENCIAS DE LA COMPUTACIÓN

Retos de introducción con dataset AMIE

Prácticum 1.2

Autor: Rivera Alulima, Mateo Gael

Tutor Externo: Vargas Naula, Francisco Oswaldo

Loja

DIAGNÓSTICO COMPLETO DEL DATASET AMIE (Archivo Maestro de Instituciones Educativas del Ecuador)

Exploración Pre-Limpieza — Criterio 1: Exploración Documentada

1. Carga del Dataset

Archivo fuente: registro-administrativo-historico_2009-2024-inicio(1).csv

Parámetros de carga inicial:

```
df = pd.read_csv(RUTA_CSV, sep=';', encoding='latin-1', low_memory=False)
```

Problema detectado en carga inicial: Al permitir que pandas infiera automáticamente los tipos de dato, las columnas numéricas con separador de miles (punto) fueron interpretadas incorrectamente como números decimales:

Valor en CSV	Interpretación incorrecta	Valor real
"1.060"	float 1.06	1060
"1.127"	float 1.127	1127
"1.665"	float 1.665	1665

Esto causo que al verificar la consistencia $Total_Estudiantes = Femenino + Masculino$, se reportaran 1,131 inconsistencias que en realidad eran artefactos de la mala interpretación del formato.

Solución aplicada:

```
df = pd.read_csv(RUTA_CSV, sep=';', encoding='latin-1', low_memory=False, dtype=str)
```

Forzar la carga de todas las columnas como string preserva el formato original del CSV sin interpretación automática de tipos por parte de pandas.

2. Pre-limpieza: Eliminación de Filas Vacías

Hallazgo: Tras la carga, se detectó que 120,114 filas (27.13% del total) estaban completamente vacías. Estas filas contenían únicamente valores NaN en todas sus columnas, probablemente generadas por saltos de línea al final del archivo CSV durante la exportación del MINEDUC.

Código aplicado:

```
filas_antes = len(df) # 442,716
df = df.dropna(how='all')
filas_eliminadas = filas_antes - len(df) # 120,114
```

Resultado:

- Filas antes: 442,716
- Filas eliminadas: 120,114 (27.13%)

- Filas después: 322,602 (72.87%)

Las filas completamente vacías no aportan información alguna y distorsionan los cálculos de porcentajes y estadísticas descriptivas.

3. Corrección de Formato Numérico

Problema identificado: El dataset utiliza el formato numérico ecuatoriano (y europeo) donde el punto actúa como separador de miles:

- 1.060
- 12.345
- 123.456

Pandas, configurado por defecto en formato anglosajón (punto como decimal), interpretaba estos valores incorrectamente.

Función de limpieza desarrollada:

```
def limpiar_numero(valor):
    if pd.isna(valor) or str(valor).strip() == "":
        return pd.NA
    s = str(valor).strip()
    # Detecta formato de miles: 1.060, 12.345, 123.456
    if re.match(r'^\d{1,3}(\.\d{3})+$', s):
        return int(s.replace('.', ''))
    # Numeros sin separadores
    try:
        return int(float(s))
    except:
        return pd.NA
```

Columnas procesadas (15 total): Cod_Provincia, Cod_Canton, Cod_Parroquia, Docentes_Femenino, Docentes_Masculino, Total_Docentes, Estudiantes_Femenino, Estudiantes_Masculino, Total_Estudiantes, Ecuatoriana, Colombiana, Venezolana, Peruana, Otros_Paises_de_America, Otros_Continentes

Evolución del problema:

Intento	Método	Resultado Docentes	Resultado Estudiantes	Estado
1	Sin limpieza	0 inconsistencias	1,131 inconsistencias	Parcial
2	str.replace('.', '') en todas las columnas	0 inconsistencias	1,131 inconsistencias (con valores 10x)	Erróneo

Intento	Método	Resultado Docentes	Resultado Estudiantes	Estado
3	Función limpiar_numero() con regex	0 inconsistencias	0 inconsistencias	Correcto

Conclusión: Es necesario detectar el patrón específico de separador de miles (`d{1,3}(\.d{3})+`) para no corromper valores que ya eran correctos.

4. Dimensiones del Dataset Limpio

Table

Métrica	Valor
Filas (registros)	322,602
Columnas (campos)	27
Periodo cubierto	2009-2010 a 2024-2025
Instituciones únicas	~322,602 / 16 ciclos ≈ 20,000 instituciones
Cobertura geográfica	24 provincias, 221 cantones, ~1,000 parroquias

5. Tipos de Dato por Columna

Columna	Tipo	Descripción
Anio_lectivo	str	Ciclo escolar (ej: "2023-2024 Inicio")
Zona	str	Zona administrativa del MINEDUC
Provincia	str	Nombre de la provincia
Cod_Provincia	int64	Código numerico de provincia (01-24)
Canton	str	Nombre del canton
Cod_Canton	int64	Código numerico de canton
Parroquia	str	Nombre de la parroquia
Cod_Parroquia	int64	Código numerico de parroquia
Nombre_Institucion	str	Nombre oficial de la institución
AMIE	str	Código unico AMIE (identificador nacional)

Columna	Tipo	Descripción
Tipo_Educacion	str	Tipo: Ordinario, Popular Permanente, Educación Especial
Sostenimiento	str	Fiscal, Particular, Fiscomisional, Municipal
Área	str	Urbana o Rural
Regimen_Escolar	str	Costa o Sierra
Jurisdicción	str	Intercultural o Intercultural Bilingüe
Docentes_Femenino	int64	Numero de docentes mujeres
Docentes_Masculino	int64	Numero de docentes hombres
Total_Docentes	int64	Total de docentes
Estudiantes_Femenino	int64	Numero de estudiantes mujeres
Estudiantes_Masculino	int64	Numero de estudiantes hombres
Total_Estudiantes	int64	Total de estudiantes matriculados
Ecuatoriana	object	Estudiantes de nacionalidad ecuatoriana
Colombiana	object	Estudiantes de nacionalidad colombiana
Venezolana	object	Estudiantes de nacionalidad venezolana
Peruana	object	Estudiantes de nacionalidad peruana
Otros_Paises_de_America	object	Estudiantes de otros paises americanos
Otros_Continentes	object	Estudiantes de otros continentes

Observación sobre tipos: Las columnas de nacionalidades (22-27) permanecen como object porque contienen valores mixtos (numéricos y nulos).

6. Análisis de Valores Nulos

Columna	Nulos	% del Total	Interpretación
Peruana	15,141	4.69%	Nacionalidad no reportada
Otros_Continentes	13,838	4.29%	Nacionalidad no reportada
Otros_Paises_de_America	13,815	4.28%	Nacionalidad no reportada

Columna	Nulos	% del Total	Interpretación
Colombiana	13,218	4.10%	Nacionalidad no reportada
Venezolana	11,204	3.47%	Nacionalidad no reportada
Ecuatoriana	1	0.00%	Caso aislado
Todas las demás	0	0.00%	Sin nulos

Las únicas columnas con valores nulos son las de nacionalidades. Esto es esperable porque la desagregación por nacionalidad no es obligatoria en todos los ciclos o para todos los tipos de institución.

Las columnas críticas para el dashboard (Total_Estudiantes, Sostenimiento, Área, AMIE, Anio_lectivo, Provincia) tienen 0 nulos, lo cual garantiza la calidad mínima necesaria para las visualizaciones requeridas.

7. Distribucion de Campos Categoricos Principales

7.1 Anio Lectivo

Ciclo	Instituciones	Ciclo	Instituciones
2009-2010 Inicio	27,651	2017-2018 Inicio	16,624
2011-2012 Inicio	27,651	2018-2019 Inicio	16,555
2010-2011 Inicio	26,919	2019-2020 Inicio	16,423
2012-2013 Inicio	26,458	2020-2021 Inicio	16,209
2013-2014 Inicio	24,573	2024-2025 Inicio	16,152
2014-2015 Inicio	23,317	2023-2024 Inicio	16,140
2015-2016 Inicio	18,625	2021-2022 Inicio	16,095
2016-2017 Inicio	17,213	2022-2023 Inicio	15,997

Tendencia: La cantidad de instituciones reportadas disminuye a partir de 2015-2016, lo cual puede deberse a:

- Fusión de instituciones
- Cierre de unidades educativas
- Cambios en los criterios de reporte del MINEDUC

7.2 Zona Administrativa

Zona	Instituciones	Zona	Instituciones
Zona 4	53,194	Zona 6	32,383
Zona 5	52,768	Zona 9	26,082
Zona 7	36,804	Zona 2	19,232
Zona 1	35,214	ZND	716
Zona 3	33,451	Zona en Estudio	8
Zona 8	32,750		

Nota: Zona 4 (Guayaquil) y Zona 5 (Quito) concentran casi 1/3 de las instituciones.

7.3 Tipo de Educación

Tipo	Instituciones	%
Ordinario	306,276	94.9%
Popular Permanente	13,959	4.3%
Educación Especial	2,367	0.7%

Nota: La modalidad Ordinaria concentra la gran mayoría de las instituciones (94.9%), mientras que la Educación Popular Permanente y la Educación Especial representan una proporción mucho menor del total.

7.4 Sostenimiento

Tipo	Instituciones	%
Fiscal	240,571	74.6%
Particular	66,233	20.5%
Fiscomisional	12,551	3.9%
Municipal	3,247	1.0%

Relevancia para P2 (dashboard): La pregunta 2 del dashboard requiere analizar "instituciones fiscales vs. particulares por área en Loja". El dataset contiene suficientes registros de ambos tipos para esta visualización.

7.5 Área (Urbana/Rural)

Área	Instituciones	%
Urbana	179,427	55.6%
Rural	143,175	44.4%

Nota: El área urbana concentra la mayor cantidad de instituciones (55.6%), aunque el área rural también representa una proporción significativa con el 44.4% del total.

7.6 Régimen Escolar

Régimen	Instituciones	%
Costa	192,319	59.6%
Sierra	130,283	40.4%

Nota: El régimen Costa concentra la mayor parte de las instituciones (59.6%), mientras que el régimen Sierra representa el 40.4% del total.

7.7 Jurisdicción

Jurisdicción	Instituciones	%
Intercultural	291,370	90.3%
Intercultural Bilingüe	31,232	9.7%

Nota: La jurisdicción Intercultural concentra la gran mayoría de las instituciones, mientras que la Intercultural Bilingüe representa menos del 10%.

8. Análisis de Duplicados

8.1 Duplicados Exactos (todas las columnas idénticas)

Resultado: 0 duplicados exactos

No existen dos filas con valores idénticos en todas sus columnas. Esto indica que cada registro tiene al menos un campo diferente, aunque pueda corresponder a la misma institución.

8.2 Duplicados por Clave Natural (AMIE + Anio_lectivo)

Resultado: 4 registros duplicados (2 pares)

Anio_lectivo	AMIE	Nombre_Institucion	Provincia
2015-2016 Inicio	17H02739	COLEGIO POPULAR PARTICULAR A DISTANCIA COMPUINFORMATICA	PICHINCHA
2015-2016 Inicio	17H02739	COMPUINFORMATICA	PICHINCHA
2019-2020 Inicio	17H03647	EDUCACION SIGLO XXI	PICHINCHA
2019-2020 Inicio	17H03647	EDUCACION SIGLO XXI	PICHINCHA

Ambos duplicados comparten el mismo patrón: la institución está ubicada en Quito (Pichincha), que geográficamente pertenece al régimen Sierra, pero una de las filas registra erróneamente Costa.

Decisión para limpieza: Eliminar las filas con régimen Costa en ambos pares, ya que contienen un error de clasificación territorial. Se mantienen las filas con régimen Sierra, que es el único geográficamente válido para instituciones en Pichincha.

9. Consistencia Numérica

9.1 Docentes: Total_Docentes vs. Docentes_Femenino + Docentes_Masculino

Formula verificada: $\text{Total_Docentes} = \text{Docentes_Femenino} + \text{Docentes_Masculino}$

Resultado: 0 inconsistencias (0.00%)

Todos los 322,602 registros cumplen con la consistencia matemática. La suma de docentes por genero coincide exactamente con el total reportado en el 100% de los casos.

9.2 Estudiantes: Total_Estudiantes vs. Estudiantes_Femenino + Estudiantes_Masculino

Formula verificada: $\text{Total_Estudiantes} = \text{Estudiantes_Femenino} + \text{Estudiantes_Masculino}$

Resultado: 0 inconsistencias (0.00%)

Tras la corrección del formato numérico, todos los registros cumplen con la consistencia. La suma de estudiantes por genero coincide exactamente con el total reportado.

Sin embargo, antes de la corrección de formato, se reportaron 1,131 inconsistencias. Todas fueron resueltas al interpretar correctamente el separador de miles. Esto demuestra la importancia de validar el formato de los datos antes de cualquier análisis.

10. Valores Cero en Campos Numéricos

Campo	Valores Cero	% del Total	Interpretación
Docentes_Femenino	43,674	13.54%	Instituciones sin docentes mujeres reportados
Docentes_Masculino	109,525	33.95%	Instituciones sin docentes hombres reportados
Total_Docentes	3,268	1.01%	Instituciones sin docentes (posible cierre o nuevo inicio)
Estudiantes_Femenino	2,090	0.65%	Instituciones solo con estudiantes hombres
Estudiantes_Masculino	3,594	1.11%	Instituciones solo con estudiantes mujeres
Total_Estudiantes	0	0.00%	Todas las instituciones tienen al menos 1 estudiante

Análisis de valores cero:

1. Docentes_Masculino (33.95% en cero):

- Instituciones con plantel docente predominantemente femenino (escuelas de educación inicial, por ejemplo)
- Otra explicación: Datos no reportados para el ciclo

2. Docentes_Femenino (13.54% en cero):

- Similar al anterior, pero menos frecuente
- Puede indicar instituciones técnicas o militares con plantel masculino

3. Total_Docentes (1.01% en cero):

- Instituciones que no reportaron docentes
- Posiblemente instituciones en proceso de apertura o cierre
- Requiere validación con el contexto del ciclo

4. Estudiantes por genero (0.65% y 1.11%):

- Instituciones unisex (solo mujeres o solo hombres)
- Común en instituciones religiosas o militares
- Valores validos dentro del contexto educativo

11. Codificación de Caracteres

Problema detectado: El archivo utiliza codificación latin-1 (Windows-1252) en lugar de UTF-8. Esto causa que caracteres especiales del español aparezcan codificados incorrectamente:

Table

Carácter correcto	Aparece como	Ubicación
Ñ	A + tilde + varios caracteres	Parroquia BAÑOS
ü (Bilingüe)	A + tilde + 1/4	Jurisdicción Bilingüe
ó (Educación)	A + tilde + 3/4	Tipo_Educacion Educaci3n

Impacto:

- Dificulta la lectura humana de los datos
- Puede causar problemas en filtros y búsquedas ("Bilingüe" != "Bilingüe")
- Requiere corrección en el paso de limpieza

12. Problema del BOM (Byte Order Mark)

Hallazgo: La primera columna del CSV incluye el BOM (Byte Order Mark) de UTF-8 al inicio del archivo, lo que causa que pandas la nombre como '¿Anio_lectivo' en lugar de Anio_lectivo.

Evidencia:

Columna detectada: '¿Anio_lectivo' (en lugar de 'Anio_lectivo')

Solución propuesta: Renombrar la columna durante la limpieza para eliminar el prefijo del BOM.

Limpieza — Criterio 2: Transformaciones de Limpieza

2.1 Carga del dataset

<pre>df = pd.read_csv(RUTA_CSV, sep=";", encoding="latin-1", low_memory=False, dtype=str)</pre>

Parámetros críticos:

- `sep=";"`: El CSV usa punto y coma como separador (formato europeo/ecuatoriano)
- `encoding="latin-1"`: El MINEDUC codifica en Windows-1252; con UTF-8 produce errores o caracteres incorrectos
- `dtype=str`: Fuerza carga como string para evitar que pandas infiera tipos y corrompa separadores de miles
- `low_memory=False`: Evita advertencias de tipos mixtos en columnas largas

2.2 Problema de codificación UTF-8 detectado

Hallazgo: El CSV original contiene texto con **doble codificación UTF-8**. Algunos campos de texto fueron guardados como UTF-8 pero el archivo declara latin-1, produciendo secuencias corruptas:

Texto que se ve en CSV	Debería ser	Causa
CAÑ'AR	CAÑAR	Bytes UTF-8 de Ñ interpretados como latin-1
Ã%o	É	0xC3 0x89 leídos como dos caracteres latin-1
Ã"	Ó	0xC3 0x93 leídos como dos caracteres latin-1
Ãš	Ú	0xC3 0x9A leídos como dos caracteres latin-1

Diagnóstico: Al abrir el CSV crudo en Notepad++ con codificación latin-1, se observan secuencias como Ã', Ã%o, Ã". Esto indica que el archivo fue creado con contenido UTF-8 pero sin BOM o con declaración de codificación incorrecta.

2.3 Solución: Revertir doble codificación UTF-8

```
def corregir_utf8(s):
    """Revierte texto que fue guardado como UTF-8 pero leído como latin-1."""
    if pd.isna(s):
        return s
    try:
        # Los caracteres "raros" son bytes UTF-8 interpretados como latin-1
        # encode("latin-1") recupera los bytes originales
        # decode("utf-8") los interpreta correctamente
        return s.encode("latin-1").decode("utf-8")
    except (UnicodeEncodeError, UnicodeDecodeError):
        return s

# Aplicar a TODO el DataFrame
for col in df.columns:
    df[col] = df[col].apply(lambda x: corregir_utf8(x) if isinstance(x, str) else x)
```

¿Por qué funciona?

Cuando un texto UTF-8 (ej. CAÑAR = bytes 43 41 C3 91 41 52) se lee como latin-1:

- El byte C3 se convierte en Ã
- El byte 91 se convierte en caracter similar
- Resultado: CAÑ'AR

Para revertir:

1. encode("latin-1") → vuelve a obtener los bytes originales 43 41 C3 91 41 52

2. `decode("utf-8")` → los interpreta correctamente como CAÑAR

Resultado: Todos los nombres de provincias, cantones, parroquias e instituciones quedan con caracteres correctos: CAÑAR, ESMERALDAS, SANTO DOMINGO DE LOS TSÁCHILAS, etc.

2.4 Eliminación de filas vacías

```
filas_antes = len(df) # 442,716
df = df.dropna(how="all")
filas_eliminadas = filas_antes - len(df) # 120,114
```

Métrica	Valor
Filas antes	442,716
Filas eliminadas	120,114 (27.13%)
Filas después	322,602

Justificación: Las filas completamente vacías no aportan información y distorsionan cálculos de porcentajes. Probablemente generadas por saltos de línea al final del CSV durante la exportación del MINEDUC.

2.5 Corrección de formato numérico

Problema: El dataset usa formato numérico ecuatoriano (punto como separador de miles):

- 1.060 = mil sesenta
- 12.345 = doce mil trescientos cuarenta y cinco
- 123.456 = ciento veintitrés mil cuatrocientos cincuenta y seis

Pandas, configurado en formato anglosajón (punto como decimal), interpretaba 1.060 como 1.06 (float).

Función desarrollada:

```
def limpiar_numero(valor):
    if pd.isna(valor) or str(valor).strip() == "":
        return pd.NA
    s = str(valor).strip()
    # Detecta formato de miles: 1.060, 12.345, 123.456
    if re.match(r"^\d{1,3}(\.\d{3})+$", s):
        return int(s.replace(".", ""))
    # Números sin separadores
    try:
        return int(float(s))
    except:
        return pd.NA
```

Evolución del problema:

Intento	Método	Resultado Docentes	Resultado Estudiantes	Estado
1	Sin limpieza	0 inconsistencias	1,131 inconsistencias	Parcial
2	str.replace(".", "") en todas las columnas	0 inconsistencias	1,131 inconsistencias (valores 10x)	Erróneo
3	limpiar_numero() con regex <code>^d{1,3}(\\.d{3})+\$</code>	0 inconsistencias	0 inconsistencias	Correcto

Conclusión: Es necesario detectar el patrón específico de separador de miles para no corromper valores que ya eran correctos.

Columnas procesadas (15 total): Cod_Provincia, Cod_Canton, Cod_Parroquia, Docentes_Femenino, Docentes_Masculino, Total_Docentes, Estudiantes_Femenino, Estudiantes_Masculino, Total_Estudiantes, Ecuatoriana, Colombiana, Venezolana, Peruana, Otros_Paises_de_America, Otros_Continentes

3. Transformación 1: Renombrar Columnas

Problema detectado

Los nombres de columnas del CSV original presentaban inconsistencias:

Table

Problema	Ejemplo en CSV	Impacto
Caracteres BOM (Byte Order Mark)	ï»¿Anio_lectivo	El prefijo invisible ï»¿ rompe referencias directas por nombre
Tildes omitidas	Anio en vez de Año	Inconsistencia con convenciones ortográficas
Mayúsculas y espacios	Nombre_Institucion	No cumple snake_case estándar en Python/SQL
Nombres descriptivos pero largos	Otros_Paises_de_America	Verboso para consultas SQL frecuentes

Verificación en carga

La columna de año lectivo fue detectada dinámicamente porque el BOM hace que su nombre literal varíe:

```
nombre_anio_original = [c for c in df.columns if "anio" in c.lower()][0]
```

Resultado: "¿Anio_lectivo" (con BOM invisible al principio)

Mapeo aplicado

Nombre original	Nombre estandarizado	Justificación
¿Anio_lectivo	anio_lectivo	Elimina BOM, minúsculas, snake_case
AMIE	cod_amie	Prefijo cod_ indica código identificador (PK)
Nombre_Institucion	nombre_institucion	Minúsculas consistentes
Total_Docentes	total_docentes	snake_case para compatibilidad SQL
Otros_Paises_de_America	otros_paises_america	Elimina preposición de, más conciso
Otros_Continentes	otros_continentes	snake_case

Resultado: 27 columnas renombradas.

4. Transformación 2: Llenar Nulos en Columnas Numéricas

Hallazgo de nulos

Tras la corrección de tipos numéricos, se identificaron valores nulos concentrados en campos de nacionalidad:

Columna	Nulos detectados	% del total	Interpretación
ecuatoriana	1	~0.00%	Dato faltante aislado
colombiana	13,218	4.10%	Nacionalidad no reportada
venezolana	11,204	3.47%	Nacionalidad no reportada
peruana	15,141	4.69%	Nacionalidad no reportada
otros_paises_america	13,815	4.28%	Nacionalidad no reportada
otros_continentes	13,838	4.29%	Nacionalidad no reportada

Campos sin nulos: total_docentes, total_estudiantes, estudiantes_femenino, estudiantes_masculino, docentes_femenino, docentes_masculino.

Decisión de limpieza

```
df[col] = df[col].fillna(0).astype(int)
```

Alternativa considerada	Descartada porque
Eliminar filas con nulos	Perdería ~15,000 registros (4.7%) sin motivo
Imputar media/mediana	La nacionalidad es categórica; imputar promedio no tiene sentido semántico
Dejar como NaN	SQLite no maneja NaN en enteros; convertiría a float, complicando SUM() y COUNT()

Justificación del cero

Según especificaciones del MINEDUC, el valor 0 en campos de nacionalidad significa **"sin datos reportados"** para ese ciclo lectivo, no que la institución tenga cero estudiantes de esa nacionalidad.

Anotación documentada: "Los valores 0 en campos numéricos representan "sin datos reportados" según las especificaciones del MINEDUC, no necesariamente indican ausencia real de personas en la institución."

5. Transformación 3: Eliminar Duplicados

Detección de duplicados

Table

Métrica	Valor
Filas duplicadas detectadas	4
Pares de duplicados	2
% del dataset	0.0012%

Análisis de casos

cod_a mie	anio_le ctivo	nombre_instit ucion	regimen_e scolar	total_estud iantes	Provincia/C antón
17H02 739	2015- 2016 Inicio	COLEGIO POPULAR PARTICULAR A	Sierra	555	PICHINCHA / QUITO

cod_amie	anio_lectivo	nombre_institucion	regimen_escolar	total_estudiantes	Provincia/Cantón
		DISTANCIA COMPUINFORMATICA			
17H02739	2015-2016 Inicio	COMPUINFORMATICA	Costa	810	PICHINCHA / QUITO
17H03647	2019-2020 Inicio	EDUCACION SIGLO XXI	Costa	59	PICHINCHA / QUITO
17H03647	2019-2020 Inicio	EDUCACION SIGLO XXI	Sierra	59	PICHINCHA / QUITO

Diagnóstico: Ambas instituciones están en Quito, Pichincha. Geográficamente, Quito pertenece a la región Sierra. La clasificación como Costa es un error administrativo del MINEDUC.

Decisión documentada

Opción	Análisis
Mantener ambos registros	Rompería unicidad de (cod_amie, anio_lectivo); contaría la misma institución dos veces
Promediar valores	No tiene sentido semántico promediar entre clasificaciones territoriales incorrectas
Eliminar aleatoriamente	Perdería control sobre cuál clasificación es correcta
Mantener Sierra, eliminar Costa	Seleccionada: Quito es geográficamente Sierra

Implementación

```
df["prioridad"] = df.apply(
    lambda row: 0 if row["regimen_escolar"] == "Sierra" else 1, axis=1
)
df = df.sort_values(["cod_amie", "anio_lectivo", "prioridad"])
df = df.drop_duplicates(subset=["cod_amie", "anio_lectivo"], keep="first")
```

Resultado:

Métrica	Valor
Filas eliminadas	2

Métrica	Valor
Filas mantenidas	2
Filas finales del dataset	322,600

6. Transformación 4: Verificar Consistencia Numérica

Verificación 1: Total de docentes

Total_docentes == Docentes_Femenino + Docentes_Masculino
--

Table

Resultado	Valor
Registros inconsistentes	0
Estado	OK

Verificación 2: Total de estudiantes

Total_Estudiantes == Estudiantes_Femenino + Estudiantes_Masculino

Resultado	Valor
Registros inconsistentes	0
Estado	OK

Justificación: El total consolidado es el dato que el MINEDUC valida a nivel nacional para estadísticas oficiales.

7. Exportación del Dataset Limpio

Parámetro	Valor
Formato	CSV intermedio
Separador	; (consistente con CSV original)
Encoding	utf-8-sig (UTF-8 con BOM para compatibilidad Excel/Power BI)
Ruta	data\procesado\dataset_limpio.csv
Filas exportadas	322,600
Columnas	27

Cambio de encoding: Inicialmente se usó latin-1 para el CSV intermedio, pero esto re-corrompía los caracteres UTF-8 ya corregidos. Se cambió a utf-8-sig para preservar Ñ, tildes y otros caracteres correctamente.

El CSV intermedio permite:

- Verificar manualmente el resultado antes de cargar a SQLite
- Ejecutar el Paso 3 independientemente sin rehacer la limpieza
- Auditar con herramientas externas (Excel, LibreOffice, DB Browser)

Carga en SQLite y Verificación de Consultas — Criterio 3

3.1 Carga del dataset limpio desde CSV intermedio

```
df = pd.read_csv(RUTA_CSV_LIMPIO, sep=';', encoding='utf-8-sig',  
low_memory=False, dtype=str)
```

Parámetros críticos:

- sep=';': El CSV usa punto y coma como separador
- encoding='utf-8-sig': El archivo intermedio fue guardado con BOM UTF-8 tras la limpieza del Paso 2; utf-8-sig maneja correctamente el BOM al inicio del archivo
- dtype=str: Fuerza carga como string para preservar integridad de datos antes de la conversión controlada de tipos
- low_memory=False: Evita advertencias de tipos mixtos en columnas con gran variabilidad de longitud

3.3 Creación de conexión SQLite

```
engine = create_engine(f'sqlite:///RUTA_DB')
```

Justificación:

- SQLite es una base de datos embebida; no requiere servidor ni instalación adicional
- El archivo .db es portable y puede conectarse directamente a Power BI/Metabase
- sqlalchemy proporciona una capa de abstracción que permite escribir SQL estándar compatible con SQLite

3.4 Carga del dataset en tabla única instituciones

```
anio_mas_reciente = sorted(df['anio_lectivo'].unique())[-1]  
# Resultado: '2024-2025 Inicio'  
df.to_sql('instituciones', engine, if_exists='replace', index=False)
```

Decisiones de diseño:

- **Una sola tabla con histórico completo:** A diferencia de esquemas normalizados, se optó por una tabla plana porque:

- El reto para cuarto ciclo no exigía implementar un modelo relacional de la base de datos
- Una tabla única simplifica la conexión desde Power BI (un solo origen de datos)
- if_exists='replace': Sobrescribe la tabla si existe, garantizando que cada ejecución del pipeline parte de datos limpios
- index=False: Evita que pandas cree una columna de índice adicional; cod_amie ya es la clave natural

Verificación de carga:

```
SELECT COUNT(*) FROM instituciones
```

Resultado	322,600 registros
------------------	--------------------------

3.5 Consulta P1: Matrícula total por provincia

```
SELECT
    provincia,
    SUM(total_estudiantes) as matricula_total,
    COUNT(cod_amie) as num_instituciones
FROM instituciones
WHERE anio_lectivo = '2024-2025 Inicio'
GROUP BY provincia
ORDER BY matricula_total DESC
```

Parámetros críticos:

- WHERE anio_lectivo = '2024-2025 Inicio': Filtra solo el ciclo más reciente, coherente con la pregunta del dashboard
- SUM(total_estudiantes): Agrega matrícula total por provincia
- COUNT(cod_amie): Cuenta instituciones únicas (no hay duplicados gracias a la limpieza del Paso 2)
- ORDER BY matricula_total DESC: Ordena de mayor a menor para el gráfico de barras horizontales

Resultados:

Provincia	Matrícula Total	Instituciones
GUAYAS	1,038,829	2,603
PICHINCHA	682,355	1,833
MANABÍ	394,439	2,168

Provincia	Matrícula Total	Instituciones
LOS RÍOS	220,955	837
AZUAY	189,698	846
EL ORO	166,937	559
ESMERALDAS	157,657	798
SANTO DOMINGO DE LOS TSÁCHILAS	133,249	402
TUNGURAHUA	128,435	289
IMBABURA	115,171	310

Hallazgo: 25 provincias en total. Matrícula nacional: 4,106,819 estudiantes.

3.6 Consulta P2: Sostenimiento por área en Loja

```
SELECT
  área,
  sostenimiento,
  COUNT(cod_amie) as num_instituciones
FROM instituciones
WHERE provincia = 'LOJA'
  AND anio_lectivo = '2024-2025 Inicio'
  AND sostenimiento IN ('Fiscal', 'Particular')
GROUP BY área, sostenimiento
ORDER BY área, sostenimiento
```

Parámetros críticos:

- WHERE provincia = 'LOJA': Filtra geográficamente para responder la pregunta específica de la provincia
- AND sostenimiento IN ('Fiscal', 'Particular'): Excluye "Fiscomisional" y "Municipal" porque el dashboard compara solo fiscal vs. particular
- GROUP BY área, sostenimiento: Produce las combinaciones necesarias para el gráfico de barras apiladas al 100%

Resultados:

Área	Sostenimiento	Instituciones
Rural	Fiscal	655
Rural	Particular	1
Urbana	Fiscal	296

Área	Sostenimiento	Instituciones
Urbana	Particular	61

Hallazgos:

- **Rural:** 656 instituciones (99.8% fiscal, 0.2% particular)
- **Urbana:** 357 instituciones (83.2% fiscal, 16.8% particular)
- La educación rural en Loja es casi exclusivamente pública; la oferta particular se concentra en zona urbana

3.7 Consulta P3: Evolución de instituciones activas (2015–2024)

```
SELECT
  anio_lectivo,
  COUNT(cod_amie) as num_instituciones,
  SUM(total_estudiantes) as matricula_total,
  SUM(total_docentes) as docentes_total
FROM instituciones
WHERE anio_lectivo LIKE '2015-2016%'
OR anio_lectivo LIKE '2016-2017%'
OR anio_lectivo LIKE '2017-2018%'
OR anio_lectivo LIKE '2018-2019%'
OR anio_lectivo LIKE '2019-2020%'
OR anio_lectivo LIKE '2020-2021%'
OR anio_lectivo LIKE '2021-2022%'
OR anio_lectivo LIKE '2022-2023%'
OR anio_lectivo LIKE '2023-2024%'
OR anio_lectivo LIKE '2024-2025%'
GROUP BY anio_lectivo
ORDER BY anio_lectivo
```

Parámetros críticos:

- WHERE ... LIKE 'XXXX-YYYY%': El dataset histórico incluye "Inicio"; el LIKE con % captura ambos variantes por año lectivo
- Se usa LIKE en lugar de = porque los valores exactos incluye el sufijo "Inicio"
- COUNT(cod_amie): Número de instituciones activas por año
- SUM(total_estudiantes) y SUM(total_docentes): Métricas adicionales para contexto del dashboard

Resultados:

Año Lectivo	Instituciones	Matrícula Total	Docentes Total
2015-2016 Inicio	18,624	4,627,136	218,553
2016-2017 Inicio	17,213	4,581,883	214,917

Año Lectivo	Instituciones	Matrícula Total	Docentes Total
2017-2018 Inicio	16,624	4,516,067	217,321
2018-2019 Inicio	16,555	4,473,021	219,866
2019-2020 Inicio	16,422	4,406,971	219,989
2020-2021 Inicio	16,209	4,314,777	206,875
2021-2022 Inicio	16,095	4,309,139	203,595
2022-2023 Inicio	15,997	4,322,138	208,876
2023-2024 Inicio	16,140	4,202,798	213,468
2024-2025 Inicio	16,152	4,106,819	215,030

Hallazgos:

- **Tendencia de instituciones:** Descenso sostenido de 18,624 (2015) a ~16,100 (2024), una reducción del 13.3%
- **Tendencia de matrícula:** Descenso de 4.6M a 4.1M estudiantes, reducción del 11.2%
- **Anomalía 2020-2021:** Caída pronunciada en docentes (206,875 vs. ~219,000 años previos), probablemente por efectos de la pandemia COVID-19
- **Recuperación 2024-2025:** Ligero repunte en instituciones (16,152) y docentes (215,030) respecto a 2023-2024

3.8 KPI: Matrícula Nacional

```
SELECT
  SUM(total_estudiantes) as matricula_nacional,
  SUM(total_docentes) as docentes_nacional,
  COUNT(DISTINCT cod_amie) as total_instituciones
FROM instituciones
WHERE anio_lectivo = '2024-2025 Inicio'
```

Justificación:

- COUNT(DISTINCT cod_amie): Aunque no hay duplicados, DISTINCT es defensivo ante futuras cargas
- Este KPI se visualiza como tarjeta grande en el dashboard ("big number" visible al inicio)

Resultados:


KPI	Valor
Matrícula nacional (2024-2025 Inicio)	4,106,819 estudiantes
Docentes nacionales	215,030
Instituciones activas	16,152

Dashboard en PowerBI

Visualización 1: ¿Cómo se distribuye la matrícula total por provincia en el año lectivo más reciente?

Gráfico 1

Suma de matrícula total por provincia




El gráfico confirma la concentración extrema de la matrícula estudiantil en pocas provincias. Guayas lidera con 1,038,829 estudiantes —casi el 25% de toda la matrícula nacional— seguida por Pichincha con 682,355. Juntas, estas dos provincias concentran aproximadamente el 42% de todos los estudiantes del país. Manabí (394,439) completa el podio. La cola del ranking muestra provincias con matrícula marginal: Galápagos y la categoría "ZONA EN ESTUDIO" tienen barras casi invisibles, evidenciando la asimetría demográfica y de oferta educativa entre la Costa/Sierra central y el resto del territorio. Esto tiene implicaciones directas en la distribución de recursos docentes e infraestructura.

Visualización 2: ¿Cuál es la proporción de instituciones fiscales vs. particulares por área (urbana/rural) en Loja?

Gráfico 2

Suma de instituciones por área y sostenimiento




El gráfico visualiza una brecha estructural brutal entre rural y urbano. En el área rural de Loja, el sostenimiento fiscal domina con un 99.8% (655 de 656 instituciones); solo existe 1 institución particular rural. En contraste, el área urbana muestra una composición más diversificada: 83% fiscal (296) y 17% particular (61). Esto indica que la educación privada en Loja —y probablemente en provincias similares del sur andino— no tiene incentivo o capacidad para expandirse a zonas rurales, dejando al Estado como único proveedor. La visualización de barras apiladas al 100% enfatiza esta disparidad proporcional: la barra rural es prácticamente monocromática (azul fiscal), mientras la urbana muestra segmentación.

Visualización 3: ¿Cómo evolucionó el número de instituciones activas en Ecuador entre 2015 y 2024?

Gráfico 3

Suma de instituciones por año lectivo



La línea describe una tendencia descendente sostenida con inflexiones puntuales. El punto más alto es 2015-2016 con 18,624 instituciones; desde ahí, la caída es pronunciada hasta estabilizarse alrededor de los 16,000 entre 2020 y 2025. La pendiente más aguda ocurre entre 2015 y 2017 (-2,000 instituciones), sugiriendo una reestructuración del sistema educativo (posible fusión de unidades educativas pequeñas o cierre de instituciones con matrícula insuficiente). El valle en 2022-2023 (15,997) y el ligero repunte en 2024-2025 (16,152) podrían reflejar recuperación post-pandemia o nuevas aperturas.

Visualización 4: KPI de matrícula nacional visible

Gráfico 4

KPI de matrícula nacional



Los tres KPIs consolidan el estado del sistema educativo ecuatoriano al inicio del ciclo 2024-2025.

Pipeline Principal — main.py

Se implementó un archivo principal (main.py) para coordinar el pipeline ETL del proyecto AMIE-MINEDUC. Su función es ejecutar de manera secuencial los scripts de diagnóstico, limpieza y carga de datos hacia SQLite.

El script también verifica la existencia de los archivos necesarios, crea automáticamente las carpetas de trabajo si no existen y detiene el proceso en caso de errores, garantizando una ejecución más organizada y segura del ETL.

Flujo de ejecución



Cada etapa procesa la salida de la anterior hasta generar la base de datos SQLite final del proyecto.